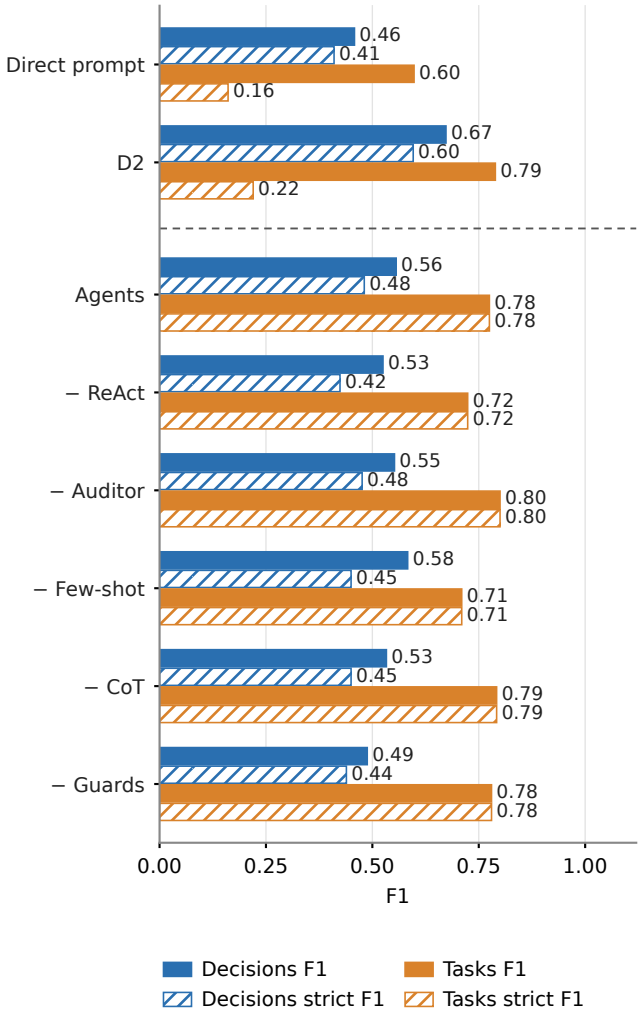
Direct prompt
0.46
0.41
0.60
0.16
D2
0.67
0.60
0.79
0.22
Agents
0.56
0.48
0.78
0.78
− ReAct
0.53
0.42
0.72
0.72
− Auditor
0.55
0.48
0.80
0.80
− Few-shot
0.58
0.45
0.71
0.71
− CoT
0.53
0.45
0.79
0.79
− Guards
0.49
0.44
0.78
0.78
0.00
0.25
0.50
0.75
1.00
F1
Decisions F1
Tasks F1
Decisions strict F1
Tasks strict F1