



1. TAREA, MODELO E INTERVENCIÓN

Tarea de D1. Convertir una reunión ruidosa en un acta JSON con meeting, decisiones finales, sustituidas y rechazadas, tareas con responsable, plazo y condición, pending_issues, review_alerts y citas literales con ID. La pauta penaliza propuestas tratadas como acuerdos, revisiones perdidas, tareas asignadas a ausentes, plazos inventados y citas que no respaldan el campo. **Modelo elegido.** ministerial-3-3b-instruct-2512-q4_K_M, digest f04aa1c738f6. Es el candidato más pequeño: clase 3B, frente a 3.8B de Phi-4 Mini y 4.7B de Qwen 3.5 4B. Además, corre localmente y en D1 recuperó 6/7 tareas. Qwen agotó 3,000 tokens y entregó JSON inválido; Phi recuperó correctamente 1/7 tareas. La cuantización reduce memoria y mantiene la cantidad de parámetros.

Intervención. Constrained decoding + tool use determinista en dos pasadas. El esquema fija claves, tipos, estados e IDs de evidencia permitidos. Python recupera cada cita con sus intervenciones vecinas, resuelve fechas desde el día de la reunión, busca indicios de reemplazo y valida IDs y formatos. Luego Ministerial revisa el borrador con esos informes. Los pesos permanecen intactos y Python coordina todas las herramientas.

Qué corrige cada pieza. El esquema evita JSON, estados y campos inválidos. El prompt y el informe de herramientas advierten sobre responsables no presentes; todavía no existe un bloqueo determinista. El resolutor de fechas atiende errores como 13:00 convertido en 01:00. La revisión de IDs y contexto reduce citas inventadas y ayuda a seguir decisiones reemplazadas.

2. EJECUCIÓN Y DISEÑO EXPERIMENTAL

Ejecutamos el sistema completo en Google Colab con una Tesla T4 de 15 GB, el hardware de respaldo declarado en D1. Usamos temperatura 0, seed 42 y contexto de 12,288 tokens. El notebook instala el entorno, descarga el modelo, procesa las reuniones, calcula las métricas y exporta respuestas crudas, conteos de tokens y JSON.

Evaluación: 10 reuniones de test, 347 intervenciones, 56 decisiones y 53 tareas de referencia. Las tres configuraciones usan las mismas entradas, el mismo modelo y el mismo criterio de emparejamiento por contenido e ID. La pauta se usa después de la inferencia. Comparamos prompt directo, JSON restringido y la intervención completa.

Configuración	JSON	F1 dec.	F1 tareas	Tiempo
Prompt directo	0/10	0.477	0.667	303.8 s
JSON restringido	10/10	0.559	0.709	197.9 s
JSON + herramientas	10/10	0.667	0.716	288.0 s

El F1 de decisiones subió 0.190 (+39.8%) y el de tareas 0.049 (+7.3%). La intervención encontró 35/56 decisiones y 39/53 tareas; el baseline encontró 21/56 y 32/53. También generó 105 IDs existentes de 105, frente a 70/75. Esta comprobación cubre la existencia del ID; el respaldo semántico requiere revisión manual.

3. PRUEBA CON EL FORMATO COMPLETO DE D1

También procesamos la reunión canónica de D1, de 69 intervenciones, con el evaluador completo. Tool use por bloques obtuvo 5/9 decisiones, 1/2 estados obsoletos, 7/7 tareas, 3/4 pendientes, 7/7 responsables y 5/7 plazos. El baseline obtuvo 3/9, 0/2, 6/7, 2/4, 6/6 y 3/6. Las asignaciones a ausentes bajaron de 2 a 0 y las citas inexactas de 3 a 0. El tiempo subió de 44.62 a 119.23 s; la precisión de decisiones bajó de 0.75 a 0.25 y la de tareas de 1.0 a 0.368.

Alcance y continuidad. El conjunto de 10 reuniones usa una pauta reducida para medir decisiones y tareas; no redefine la salida de D1. El formato completo de D1 se evaluó por separado sobre la reunión canónica, incluyendo pendientes, alertas y citas literales. Por eso, los F1 agregados se limitan a decisiones y tareas y la prueba completa se reporta como evidencia complementaria, no como otra corrida del mismo pipeline.

4. ALTERNATIVAS Y ABLACIONES

Alternativa	Resultado observado
Descomposición de prompt	En 10 reuniones, v3 subió el recall de decisiones de 54.7% a 65.4%. Los responsables correctos bajaron de 35 a 27 y la latencia se duplicó.
JSON restringido	Logró 10/10 esquemas válidos y F1 de 0.559/0.709. Persistieron errores de estado y fecha.
Tool use por bloques (S2)	En D1 completo recuperó 7/7 tareas y 5/9 decisiones. Los fragmentos adicionales dejaron precisiones de 0.368/0.250.
S2 + RAG (S3)	Recuperó 6/9 decisiones y 7/7 tareas, con precisiones de 0.240/0.438. El retrieval léxico agregó resultados espurios.
RAG + verificador (S4)	Usó 85 llamadas y 127.17 s. La mejora fue marginal y perdió pendientes correctos.
Todo el pasado	Recuperó 2/2 estados obsoletos. Tardó 155.48 s y obtuvo 0.333 de precisión en tareas.

Decisión. Elegimos JSON restringido con herramientas en dos pasadas porque obtuvo los mejores F1 del conjunto de 10 y generó 10/10 esquemas válidos. RAG y el verificador aumentaron el costo y aportaron poco. Su uso en reuniones mayores a 8K queda pendiente de validación.

5. CASO DE FALLA REAL: M01

M01 es la primera reunión del conjunto según el orden de los archivos. El baseline tardó 107.16 s y produjo un esquema inválido, con 7 decisiones y 4 tareas. La intervención tardó 26.89 s, entregó un esquema válido, con 6 decisiones y 5 tareas, y usó IDs existentes. La salida todavía presentó estos errores:

- fusionó dos fechas obsoletas del lunes y clasificó una como rejected en vez de superseded;
- marcó tareas acordadas como pending, fusionó preparar/enviar el correo y omitió como tareas separadas presentar la demo y revisar el borrador;
- convirtió “antes de las seis” en 17:00 al mezclarlo con la hora de revisión;
- inventó 2026-09-23 como plazo para definir el escenario.

Por qué falla. Las herramientas comprueban sintaxis e IDs. La relación semántica entre una cita y cada campo queda a cargo del modelo. Al leer intervenciones vecinas, Ministerial mezcló la hora de revisión con la de envío. La segunda pasada también heredó omisiones del borrador y aplicó estados de decisión a tareas.

6. LIMITACIONES

- La mejora se concentra en formato y cobertura. Del baseline a la intervención, la exactitud de estado pasó de 0.528 a 0.500; responsable, de 0.969 a 0.923; plazo, de 0.406 a 0.308; y cita exacta, de 0.849 a 0.824.
- Las 10 reuniones son sintéticas. El emparejamiento es automático y aproximado, y el tamaño de la muestra impide estimaciones estables. Nuevos ajustes requieren otro conjunto de test.
- Un ID válido puede citar una intervención irrelevante. Falta una revisión humana de la evidencia. La versión de Ollama y el hardware también afectan tiempos y salidas.
- RAG sobre contextos mayores a 8K pasó pruebas mecánicas. Todavía falta evaluarlo con una reunión larga anotada.

7. REPRODUCIBILIDAD Y DEMOSTRACIÓN

Repositorio: [genai-vio-meeting-minutes](#). El [README D2](#) explica la reproducción: abrir Ministerial_Minutas_Colab.ipynb, elegir una T4, ejecutar las celdas, subir Fine Tuning.zip y descargar los resultados. Ese archivo contiene el dataset; los pesos permanecen intactos. El pipeline complementario de D1 se ejecuta con experimentos/rag_tool_use/run.py; sus 13 pruebas unitarias pasan.

Video (< 3 min): mostrar el commit y ejecutar en T4 baseline e intervención sobre M01, la primera entrada del test, con DEMO_ONLY=True. Comparar ambas salidas, mostrar brevemente el resultado completo del caso D1 y cerrar con la tabla de 10 reuniones y un error concreto. Entrada, progreso y archivos quedan visibles.